

title: "Cours_1"
author: "Simon Gabay"
date: "2/16/2020"
output: html_document

```
knitr::opts_chunk$set(echo = TRUE)
```

```
setwd("~/Desktop/Cours_Geneve/Cours_Geneve_1")  
#if (!require("ggplot2")) install.packages("ggplot2")  
library(ggplot2)
```

1 Sémantique

J- Bertin

- Jacques Bertin (1967), *Sémiologie graphique. Les diagrammes. Les réseaux. Les cartes*, Paris/La Haye, Mouton ; Paris, Gauthier-Villars.
- "La graphique": un système dont les éléments, ou signes, ont une signification fixée à l'avance et unique, ce qu'exprime par exemple la légende d'une carte (1973, 6).
- "Efficacité graphique": "si pour obtenir une réponse correcte et complète à une question donnée, et, toutes choses égales, une construction requiert un temps d'observation plus court qu'une autre construction, on dira qu'elle est plus efficace pour cette question". (1967, 139)


Loi du moindre effort

Il y a un glissement de la représentation qui se doit d'être exhaustive, précise et complète, à la représentation qui se doit d'être effiface.

- George Kingsley Zipf, *Human Behaviour and the Principle of Least Effort: An Introduction to Human Ecology* 1949
- Une observation : Plus un mot est fréquent, plus il est court.
- Cela implique que la variété, la probabilité et la distribution des mots est presque la même pour beaucoup de langues.
- L'homme qui parle tend à réduire le vocabulaire en rassemblant derrière un simple mot une multitude de significations.
- Corollaire de la loi du moindre effort: "coût mental de la perception" (Palsky 2017)

Grammaire graphique

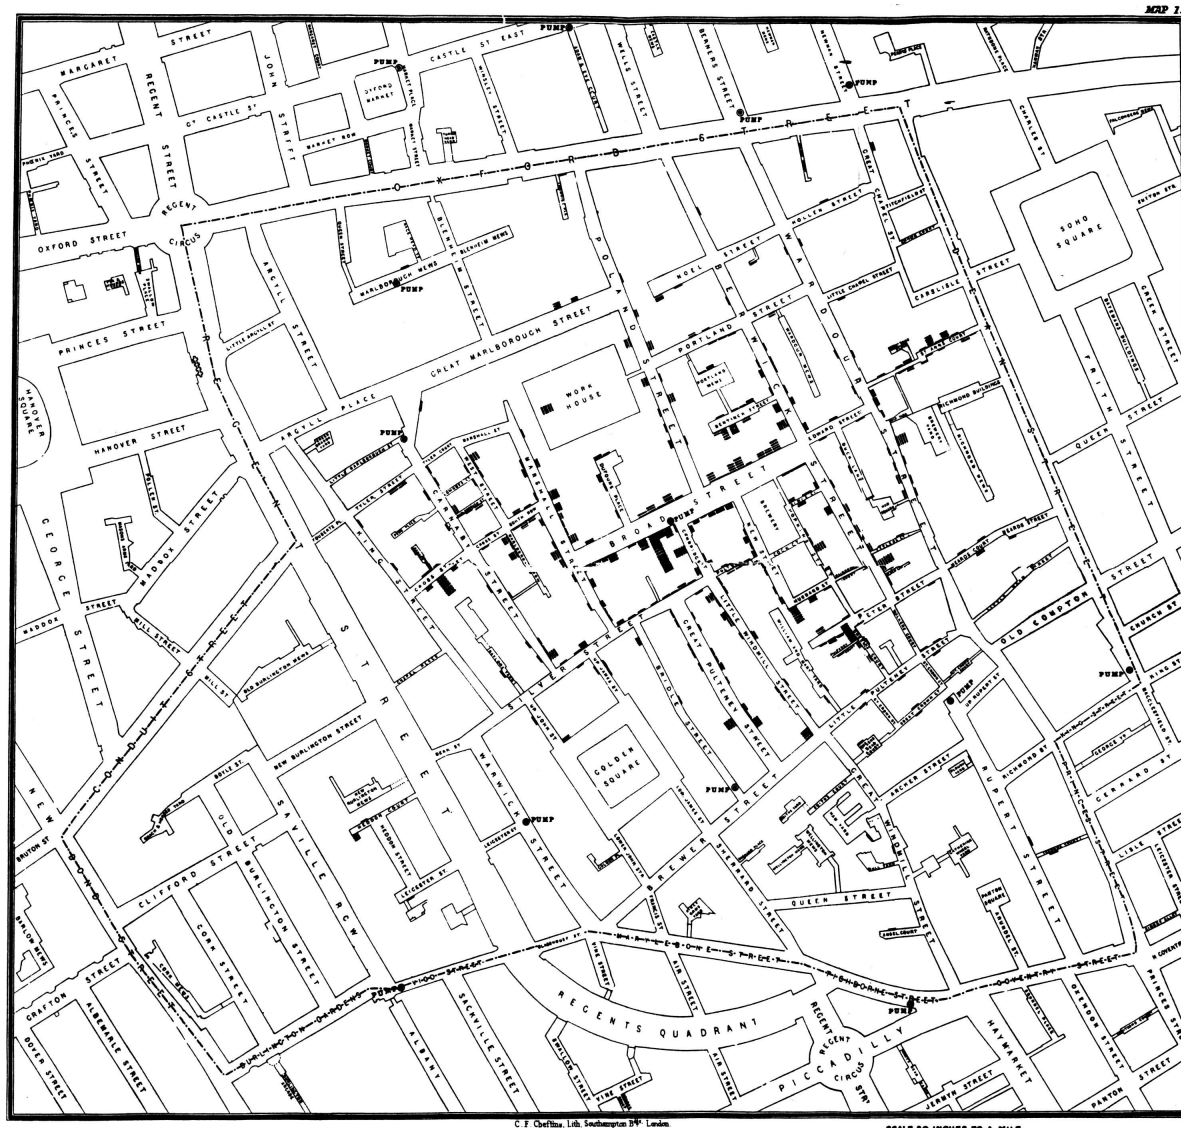
J. Bertin propose une grammaire graphique afin d'améliorer l'efficacité des rendus



Source: [Palsky 2017/Bertin 1967](#)

La carte de Snow

- John Snow (1813-1858)
- Épidémie de choléra de *Broad Street* en 1854
- Les trois jours suivants, 127 personnes habitant Broad Street ou les environs meurent. Les semaines qui suivent, les trois quarts des habitants ont fui le quartier. Le 10 septembre, 500 personnes étaient mortes. En tout, l'épidémie a fait 616 morts.
- À l'époque, la théorie des miasmes attribue au « mauvais air » le choléra: Snow va permettre de localiser l'origine de l'épidémie, une pompe publique, avec la base d'une répartition géographique des cas.



Source: [wikipedia](https://en.wikipedia.org/wiki/File:Map_1_of_London_1841.jpg)


La campagne de Russie par Minard

- Charles Joseph Minard (1781-1870)
- Ingénieur célèbre pour ses inventions dans le domaine de la traduction graphique et cartographique appliquée au génie civil et aux statistiques.
- Carte figurative des pertes successives en hommes de l'armée française dans la campagne de Russie 1812-1813
- Cette carte est un diagramme de Sankey (avant l'heure), c'est-à-dire un diagramme de flux.

Carte Figurative des pertes successives en hommes de l'Armée Française dans la campagne de Russie 1812-1813.

Dressée par M. Minard, Inspecteur Général des Ponts et Chaussées en retraite Paris, le 20 Novembre 1869.

Les nombres d'hommes présents sont représentés par les largeurs des zones colorées à raison d'un millimètre pour dix mille hommes; ils sont de plus écrits en travers des zones. Le rouge désigne les hommes qui ont été en Russie, le noir ceux qui en sont sortis. Les renseignements qui ont servi à dresser la carte ont été puisés dans les ouvrages de M. M. Thiers, de Legu, de Fezensac, de Chambray et le journal inédit de Jacob, pharmacien de l'Armée depuis le 28 Octobre. Pour mieux faire juger à l'œil la diminution de l'armée, j'ai supposé que les corps du Prince Nisème et du Maréchal Davout qui avaient été détachés sur Minsk et Mohilow et qui rejoignent vers Orscha et Witebsk, avaient toujours marché avec l'armée.



Auég. par Regnier, à Par. 5^{me} Marie 5^{me} 0^{me} à Paris.

Imp. Lit. Regnier et Desobry.

Source: [wikipedia](https://en.wikipedia.org/wiki/Minard's_map_of_the_French_retreat_from_Moscow)

Le Mémorial des anciens combattants du Viêt Nam

- Washington, D.C.
- Oeuvre de Maya Lin en 1982
- Statues de trois soldats
- Mur de granit noir de Bangalore long de 150 m sur lequel sont gravés les noms des 58,156 Américains tués ou portés disparus pendant cette guerre, **dans l'ordre chronologique de leur disparition**, entre 1959 et 1975.



Source: [wikipedia](#)

Tufte

Les exemples précédemment présentés proviennent des travaux d'Edward Tufte (1942-),

- Spécialiste de graphisme d'information (*Infographic, informational graphics, Information design*)
- Auteur de *The Visual Display of Quantitative Information*, 1983

Quelques concepts importants:


- *lie factor*
- *Data-ink ratio*
- *Data density*
- *Chartjunk*
- *Small multiples*
- *Sparkline*

Lie factor


Surreprésentation ou Sous-représentation ce qui se trouve dans les données

$$\text{Lie Factor} = \frac{\text{size of effect shown in graphic}}{\text{size of effect in data}}$$

This line, representing 18 miles per gallon in 1978, is 0.6 inches long.



This line, representing 27.5 miles per gallon in 1985, is 5.3 inches long.




Data-ink ratio

Surreprésentation ou Sous-représentation ce qui se trouve dans les données


$$\begin{aligned}\textbf{Data-ink ratio} &= \frac{\textbf{Data-ink}}{\textbf{Total ink used to print the graphic}} \\ &= \textbf{proportion of a graphic's ink devoted to the non-redundant display of data-information} \\ &= \textbf{1.0 - proportion of a graphic that can be erased}\end{aligned}$$

Source: [info-vis wiki](#)

Data-ink ratio



Source: [info-vis wiki](#)




Source: [info-vis wiki](#)

Data density

Il s'agit de la proportion du graph dédiée à la représentation des données.

$$\text{Data density} = \frac{\text{Number data items}}{\text{Area of data in graphic}}$$




Source: [pparacch](#)

Chart junk

Se traduit en français par "bruit graphique" (littéralement "tableau déchet").

« Les décorations intérieures aux graphiques sont autant d'encre qui ne dit rien de nouveau au lecteur. La raison d'être de la décoration varie — faire apparaître le graphique comme plus scientifique et précis [expert], vivifier le style, donner la possibilité à l'illustrateur de faire la preuve de ses talents artistiques. Quelle qu'en soit la raison, c'est autant d'encre-sans-information ou d'encre-répétant l'information, et donc souvent du chartjunk [bruit graphique inutile]. »

Chart junk




Source: <https://junkcharts.typepad.com>

Small multiples

After Great Recession, debt increased substantially in most G-7 economies

Total gross debt as a share of GDP in the Group of Seven nations



Note: Gross debt represents total liabilities of all levels and units of government — national, state/provincial and local — less liabilities held by other levels or units of government, unless otherwise noted by source.


Source: The International Monetary Fund, World Economic Outlook, accessed Sept 7, 2017.

PEW RESEARCH CENTER

Source: [Pew research center](#)

Sparkline



Elle permet de commenter une courbe  dans la phrase, sans ajouter aucun chiffre, pour expliquer une tendance (ici un léger regain).

Source: [Pew research center](#)

Franco Moretti

- Prof à Stanford
- *Atlas of the European novel, 1800-1900*, 1998
- *Graphs, Maps, Trees: Abstract Models for a Literary History* (2005), 2005
- *Distant Reading*, 2013

Moretti tente d'analyser un "système mondial de la littérature" sur des principes similaires à ceux de l'économiste Immanuel Wallerstein, qui analyse le "système-monde" sur la base de rapports qu'entretiennent le "centre", la "semi-périphérie" et la "périphérie".


Une telle approche requiert un très grand nombre de documents: il devient impossible de pratiquer ce que les anglo-saxons appellent le *close reading* (commentaire de texte): il faut prendre de la hauteur et essayer un *distant reading*.

FIGURE 8: Market quotas of British hegemonic forms, 1760–1850

All works of art, and not only parodies, are created either as a parallel or an antithesis to some model. The new form makes its appearance not in order to express a new content, but rather to replace an old form that has already outlived its artistic usefulness.

Viktor Shklovsky, *A Theory of Prose*

As more and more novels are published every year, the hegemony of a single genre tends to become less and less absolute: whereas epistolary novels amounted to 30 per cent or more of the market for twenty-five years (and over 50 per cent in the late 1770s), gothic novels only passed the 30 per cent mark for a few years, otherwise hovering around 20 per cent, and historical novels did even worse: all signs of the growing fragmentation of the market into distinct niches which I mentioned earlier. (A full computation of print runs and reprints may however alter this general picture.)



Source: [Moretti 2005](#)

Johanna Drucker

Prof. à UCLA

- « tournant design des humanités numériques »
- Regret du logocentrisme (*the text-based approach typical of traditional humanities*): il faut «surmonter l'ancienne résistance des humanists aux formes visuelles de la production de connaissance»
- L'objectif est d'«empêcher les humanités numériques de tomber dans la pure application technique de pratiques standardisées» (calcul statistique, calcul d'ingénieur, gestion technicienne d'information...) et de chercher au contraire à «créer des capacités inventives et ouvertes susceptibles de changer les paramètres»

« La posture qui domine dans le champ du design d'information repose presque entièrement sur l'idée que les données pré-existent à leur affichage et que la tâche qui consiste à leur donner une forme visuelle consiste purement à transformer un exercice cognitif en un exercice perceptif. Si la valeur d'un design d'information intelligent dans l'interprétation de données statistiques ne saurait être surestimée, et ne pas prendre cela en compte serait ridicule, les limites de cette approche doivent aussi être soulignées. Pourquoi? Parce qu'elle restreint les conditions de la connaissance en suggérant que l'information existe indépendamment de sa présentation visuelle et attend simplement de recevoir la «meilleure» forme dans laquelle elle pourra être représentée.» (Drucker 2004)

Au delà du *design*

La "simple" question du design a désormais débouché sur des interrogations plus larges qui relèvent de l'interaction homme-machine (IHM, *Human–computer interaction*).

- VRE pour *Virtual research environment*
- UX pour *User experience*

2 Des chiffres et des lettres

Data types dans R (et partout ailleurs)

On peut additionner des chiffres (*int* pour *integer*, "entier")

```
1+2
```

Il est en revanche impossible d'additionner un chiffre avec une lettre (*str*, pour *string*, "chaîne (de caractères)": *Error in 1 + "b" : non-numeric argument to binary operator*)

```
1+"b"
```

On remarque que les *str* sont notés entre guillemets. On peut ainsi spécifier qu'un chiffre est utilisé comme caractère et non comme un chiffre en utilisant les guillemets: il est alors impossible de s'en servir pour un calcul

```
"1"+2
```

Cette distinction entre *str* et *int* est fondamentale dès lors que l'on veut visualiser des données. Dans de nombreux cas, la visualisation nécessite de manipuler les données, or celles-ci peuvent être réalisées parfois sur des *str* ou *int*, mais dans certains cas uniquement sur des *int*. Un exemple tout simple serait l'addition: on ne peut effectuer l'addition "4+voiture" dans la vraie vie comme dans un ordinateur.

On va parler de données "catégorielles" et de données "métriques". La différence entre ces types de données est majeure, car elle va limiter les visualisations possibles: s'il est possible de faire une AFC ou de construire avec des données catégorielles, il est impossible de faire un ACP sans des données métriques. Il en va de même pour construire un arbre de décision (données catégorielles et métriques) et une régression linéaire (données métriques uniquement).

Notre mini-corpus

Texte 1

« **Rome**, l'unique objet de mon ressentiment !
Rome, à *qui* vient ton bras d'immoler mon amant !
Rome *qui* t'a vu naître, et que ton cœur adore !
Rome enfin que je hais parce qu'elle t'honore ! »

Corneille, Camille dans *Horace*, acte IV, scène 5

Texte 2

« **Rome**, par une loi, *qui* ne se peut changer,
N'admet avec son sang aucun sang étranger,
Et ne reconnaît point les fruits illégitimes,
Qui¹ naissent d'un hymen contraire à ses maximes. »

Racine, *Bérénice*, acte II, scène 2

Prenons la fréquence de deux mots uniquement: "Rome" et "qui"


Token	Corneille	Racine
Rome	4	2
qui	2	1

On crée deux vecteurs qui contiennent ces informations:

```
x <- c(4, 2)
y <- c(2, 1)
x
y
```


On les replace sur un plan:

```
png(file="images/plot1.png")  
plot(x,y)  
dev.off()
```




On rajoute quelques informations pour faciliter la lecture du graphique

```
png(file="images/plot2.png")  
plot(x,y, xlab="abscisse", ylab="ordonnée",  
      main="mon plan", pch=16, col="green")  
dev.off()
```




Ces points représentent des faits linguistiques calculés à partir des fréquences dans notre corpus. L'écart qui sépare ces points représente l'écart entre deux pratiques stylistiques:

```
png(file="images/plot3.png")
plot(x,y, xlab="abscisse", ylab="ordonnée",
     main="mon plan (2)", pch=16, col="green")
s <- seq(length(x)-1) # one shorter than data
segments(x[s], y[s], x[s+1], y[s+1], col= 1:3)
segments(x[s], y[s], x[s+2], y[s+2])
dev.off()
```



Il faut donc calculer comment aller du point A au point B

```
png(file="images/plot4.png")
plot(x,y, xlab="abscisse", ylab="ordonnée",
     main="mon plan (3)", pch=16, col="green")
s <- seq(length(x)-1) # one shorter than data
arrows(x[s], y[s], x[s+1], y[s+1], col= 'pink')
dev.off()
```



On peut complexifier le problème en ajoutant un troisième auteur:

C'est Rome *qui* demande nos larmes : **Rome** ! La Maîtresse de l'univers ; **Rome** ! Mère féconde des héros, et les délices des Dieux ; **Rome** ! Qui humiliait l'orgueil des tyrans de la Terre, et *qui* brillait les fers des Nations hélas !


Boyer, *Caton*, Acte IV, scène XII

Cela nous donne le tableau suivant:

Token	Corneille	Racine	Boyer
"Rome"	4	2	3
"qui"	2	1	2

Nous obtenons donc un nouveau graph:


```
x <- c(4,2,3)
y <- c(2,1,2)
png(file="images/plot5.png")
plot(x,y, xlab="abscisse", ylab="ordonnée",
     main="mon plan (4)", pch=16, col="green")
s <- seq(length(x)-1) # one shorter than data
segments(x[s], y[s], x[s+1], y[s+1], col= 1:3)
segments(x[s], y[s], x[s+2], y[s+2])
text(x=3.95, y=1.9, labels="Corneille")
text(x=3.1, y=1.95, labels="Boyer")
text(x=2.2, y=1, labels="Racine")
dev.off()
```



De l'importance des mathématiques (pour les nuls)

Il est donc possible de calculer la distance entre ces trois textes pour voir lesquels sont potentiellement les plus similaires, par exemple avec une distance euclidienne.

(Pour rappel, la distance entre deux points A et B est la racine carrée de la somme des carrés des différences de coordonnées en X et en Y.)



$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

En faisant un rapide calcul, on peut donc confirmer notre validation par nos calculs de distance:

```
# sqrt((x1-x2)**2+(y1-y2)**2)
CoRa <- sqrt((4-2)**2+(2-1)**2)
cat("Distance Corneille/Racine = ", CoRa, "\n")
CoBo <- sqrt((4-3)**2+(2-2)**2)
cat("Distance Corneille/Boyer = ", CoBo, "\n")
RaBo <- sqrt((2-3)**2+(1-2)**2)
cat("Distance Racine/Boyer = ", RaBo)
```

On intègre les distances dans le plan

```
x <- c(4,2,3)
y <- c(2,1,2)
png(file="images/plot6.png")
plot(x,y, xlab="abscisse", ylab="ordonnée",
      main="mon plan (5)", pch=16, col="green")
s <- seq(length(x)-1) # one shorter than data
segments(x[s], y[s], x[s+1], y[s+1], col="red")
segments(x[s], y[s], x[s+2], y[s+2], col="red")
text(x=3.95, y=1.9, labels="Corneille", col="black")
text(x=3.1, y=1.95, labels="Boyer", col="black")
text(x=2.2, y=1, labels="Racine", col="black")
text(x=3, y=1.4, labels="2.2", col="blue") #CoRa
text(x=2.5, y=1.6, labels="1.4", col="blue") # RaBo
text(x=3.4, y=1.95, labels="1", col="blue") # CoBo
legend("topleft", legend=c("Auteur", "Dist. euclidienne")
      text.col = c("black", "blue"), cex=0.8)
dev.off()
```


mon plan (5)

